

UNIDAD DE PROCESAMIENTO GRAFICO(GPU)

Introducción

En este artículo se dará una breve explicación acerca de la funcionalidad, aplicaciones y evolución de la GPU a través del tiempo ,se tomará como referencia a partir del año 2012 hasta el 2016, donde podremos observar el estado actual de la arquitectura.

¿Qué es la GPU?

Graphics Processing Unit, o en nuestra lengua, la Unidad de Procesamiento Gráfico. Se trata de un procesador que se dedica exclusivamente al procesamiento de gráficos u operaciones de "coma flotante". Lo que hace la GPU es aligerar de trabajo a la CPU, sobre todo a la hora de abrir juegos o aplicaciones con gráficos interactivos 3D.

Arquitectura de la GPU

Una GPU está altamente segmentada,es decir,utiliza la arquitectura paralela ,taxonomía de Flynn SIMD(Single instruction multiple data) lo que indica que posee gran cantidad de unidades funcionales. Estas unidades funcionales se pueden dividir principalmente en dos: aquéllas que procesan vértices, y aquéllas que procesan píxeles. Por tanto, se establecen el vértice y el píxel como las principales unidades que maneja la GPU.

| DYNAMIC PA | ARALLELISM |
|------------|------------|
| CPU GPU | CPU GPU |
| | |

La siguiente tabla proporciona la información de las modificaciones que se han implementado en la arquitectura Maxwell frente a la arquitectura anterior Kepler.

| | NVIDIA GeForce GTX 980 Specifications | | | | |
|----------------------|---------------------------------------|---------------------|---------------------|--|--|
| | GeForce GTX 980 | GeForce GTX 770 | GeForce GTX 780 Ti | | |
| Architecture | 28nm Maxwell | 28nm Kepler | 28nm Kepler | | |
| GPU Codename | GM204-400 | GK104-425 | GK110-425 | | |
| Die Size | 398 mm ² | 294 mm ² | 581 mm ² | | |
| L2 Cache | 2 MB | 512 kB | 1.5 MB | | |
| Transistors | 5.2b | 3.54b | 7.08b | | |
| CUDA Cores | 2048 | 1536 | 2880 | | |
| TMUs | 128 | 128 | 240 | | |
| ROPs | 64 | 32 | 48 | | |
| Base Clock | 1126 MHz | 1046 MHz | 875 MHz | | |
| Boost Clock | 1216 MHz | 1085 MHz | 928 MHz | | |
| Memory Clock | 1750 MHz | 1750 MHz | 1750 MHz | | |
| Memory | 4GB GDDR5 | 2GB GDDR5 | 3GB GDDR5 | | |
| Memory Bus | 256-bit | 256-bit | 384-bit | | |
| Bandwidth | 224 GB/s | 224 GB/s | 336 GB/s | | |
| FP Performance (SP) | 4.6 TFLOPs | 3.2 TFLOPs | 5.1 TFLOPs | | |
| Pixel Fillrate | 72.1 GP/s | 33.5 GP/s | 53.3 GP/s | | |
| Texture Fillrate | 144 GT/s | 134 GT/s | 213 GT/s | | |
| Power Connectors | 6pin + 6pin | 6pin + 8pin | 6pin + 8pin | | |
| Thermal Design Power | 165W | 230W | 250W | | |

La arquitectura Maxwell-Nvidia (Geforce GTX 980) esta diseñada especialmente para el procesamiento de imágenes en 3D y video juegos.

Comparando con la arquitectura anterior Kepler la mejora que se realizó fue en cuanto al rendimiento,consumo de energía,la cache es más grande y eficiente,nuevo núcleo de nomenclatura con 2 GB de memoria GDDR5 e y un TDP de 75 vatios que permitiría alimentarse únicamente de la energía vía *PCI-Express*, sin conectores adicionales desde la fuente de alimentación.

La siguiente tabla proporciona la información de las modificaciones que se han implementado en la arquitectura Pascal frente a la arquitectura anterior Maxwell.

| GTX1070 Details Specification Comparison | | | | | |
|--|--------------|--------------|--------------|--|--|
| Graphics | GTX1080 | GTX1070 | GTX980Ti | | |
| Architecture | Pascal | Pascal | Maxwell | | |
| Core Model | GP104 | GP104 | GM200 | | |
| The number of transistors | 7200000000 | 7200000000 | 8000000000 | | |
| Craftsmanship | 16 nanometer | 16 nanometer | 28 nm | | |
| Stream Processor | 2560 | 1920 | 2816 | | |
| Texture units | 160 | 120 | 176 | | |
| ROPs | 64 | 64 | 96 | | |
| Flops | 8.8TFLOPs | 6.5TFLOPs | 5.6TFLOPs | | |
| Memory capacity | 8GB | 8GB | 6GB | | |
| Memory Type | GDDR5X | GDDR5 | GDDR5 | | |
| Memory Interface | 256bit | 256bit | 384bit | | |
| Core frequency | 1607-1733MHz | 1506-1683MHz | 1000-1076MHz | | |
| TDP | 180W | 150W | 250W | | |
| External power supply | 8pin | 8pin | 6 + pin | | |

Estado del Arte (Comparativo)

En la actualidad no hubo ninguna modificación en cuanto a la clasificación de los algoritmos de quicksort, merge sort y radix sort (ordenación rápida, ordenamiento por mezcla, y ordenamiento de raíz).

Se realizó modificaciones y mejores a las GPU anteriores se realizaron mejoras en cuanto al rendimiento, velocidad, consumo de energía , capacidad de ejecutar operaciones, procesamiento de imágenes y video juegos.

Conclusión

Actualmente, las GPUs están disponibles en la mayoría de las tarjetas gráficas porque son utilizadas para realizar las operaciones en paralelo necesarias para obtener el color y la intensidad de los píxeles. Gracias a la rápida evolución de las GPUs durante los últimos años podemos realizar eficientemente cálculos en paralelo.

Gracias a millones de GPUs CUDA vendidas hasta la fecha, miles de desarrolladores, científicos e investigadores están encontrando innumerables aplicaciones prácticas para esta tecnología en campos como el procesamiento de vídeo e imágenes, la biología y la química computacional, la simulación de la dinámica de fluidos, la reconstrucción de imágenes de TC, el análisis sísmico o el trazado de rayos, entre otras.

La arquitectura Pascal-Nvidia(Geforce GTX 1080) ,la mejora que se realizó a la arquitectura MaxWell, a la cual se le mejoró el rendimiento ,su capacidad para **ejecutar operaciones de Precisión Mixta.** A lo que se refiere es que el GPU podrá realizar operaciones de punto flotante de precisión media (FP16) al doble de velocidad que operaciones punto flotante de simple precisión (FP32).

Está mejora es importante debido a que las arquitecturas anteriores Kepler y MaxWell solo pueden ejecutarlas a la misma velocidad.

Otra de los atributos especiales de la arquitectura también será **el uso de memoria con diseño tridimensional (3D)**. De esta manera no solo se podrá usar hasta 32GB de RAM sino también **el ancho de banda de memoria a 750 GB/s.**

Finalmente, la última pieza revelada hasta ahora es la **interconexión NVLink** que jugará un papel importante en cómo se comunican los GPUs y la posibilidad de **mejorar el escalamiento con hasta 64 GPUs.**

Presentado por:

Johanna Alejandra Jurado Uribe

Juan Carlos Patiño Hernändez

Juan Camilo Olmos Oliveros

Presentado a:

Yensy GómezVillegas

Universidad Tecnólogica de Pereira

Pereira, Noviembre de 2016